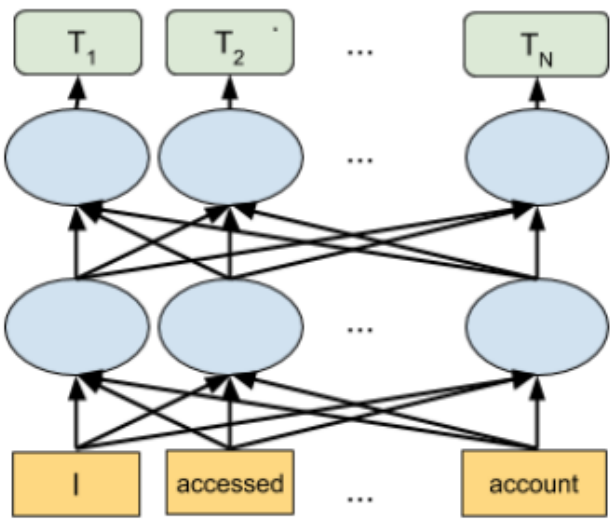
Контекстные эмбеддинги слов и предложений

Виктор Китов
victorkitov.github.io



Содержание

1. Постановка задачи
2. Модель ELMo
3. Модель BERT
4. Извлечение ответа из контекста

Эмбеддинги на текстах

- При обработке текстов слова представляются эмбеддингами.
- Эмбеддинг - представление токенов в виде вещественных векторов
  - небольшого и фиксированного размера.
- Хотим получить информативные эмбеддинги слов для решения задач на текстах.

Задачи, использующие эмбеддинги токенов

- **Распознавание именованных сущностей** (Named Entity Recognition, NER)
  - Нужно различать “Apple” как компанию или фрукт.
- **Разметка частей речи** (Part-of-Speech Tagging, POS)
  - Слово “play” может быть существительным или глаголом в зависимости от контекста.
- **Разрешение неоднозначности слов** (Word Sense Disambiguation, WSD)
  - bank как финансовая организация или как берег реки?
- **Разметка семантических ролей слов** (Semantic Role Labeling, SRL)
  - Маша читала книгу в библиотеке =>
    - кто? Маша
    - что делала? читала
    - что именно? книгу
- Контекстные эмбеддинги важны для корректного перевода и ответа на вопросы, т.к. смысл слов зависит от контекста.

Адаптация к контексту

- Проблема word2vec - не учитывает контекст!
  - лук (овощ/оружие), ключ (инструмент, источник воды) и т.д.
- Можем получать эмбеддинги из скрытого состояния RNN
  - учитывает только левый контекст
- Учёт и левого, и правого контекста
  - двунаправленная RNN - ELMo (Embeddings from Language Models[1])
  - кодировщик трансформера (BERT-подобные модели)

[1] Peters M. E. et al. Deep contextualized word representations. arXiv 2018 //arXiv preprint arXiv:1802.05365. – 2018.

Содержание

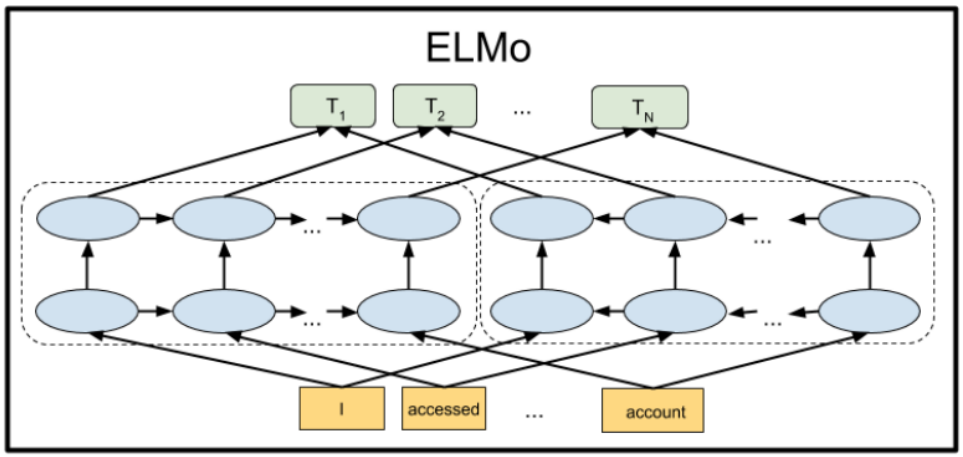
1 Постановка задачи

2 Модель ELMo

3 Модель BERT

4 Извлечение ответа из контекста

ELMo: обучение



- Две L-слойные LSTM ($L = 2$) предобучались решать задачу предсказания
  - следующего слова для forward-LSTM
  - предыдущего слова для backward-LSTM

ELMo: применение

- Слову $w_i \to h^l = \left\{x_i; \overrightarrow{h}^l_i; \overleftarrow{h}^l_i\right\}$ на слоях $l = 1, ..L$, где
  - x_i - начальный (неконтекстный) эмбеддинг слова w_i
  - $\overrightarrow{h}^l_i$ - скрытое состояние forward-LSTM
  - $\overleftarrow{h}^l_i$ - скрытое состояние backward-LSTM
- Итоговое представление: h_i^L либо $\sum_{l=1}^L \alpha_l h_i^l$
  - с настраиваемыми $\{\alpha_l\}_l$.
- Использование:
  - входные исходные эмбеддинги токенов конкатенируются с представлением токенов в ELMo.
  - при использовании многоуровневой RNN можно дополнять скрытые состояния нашей сети скрытыми состояниями с соответствующих слоёв ELMo.

Начальные эмбеддинги слов

- Пусть слово представляется T символами:

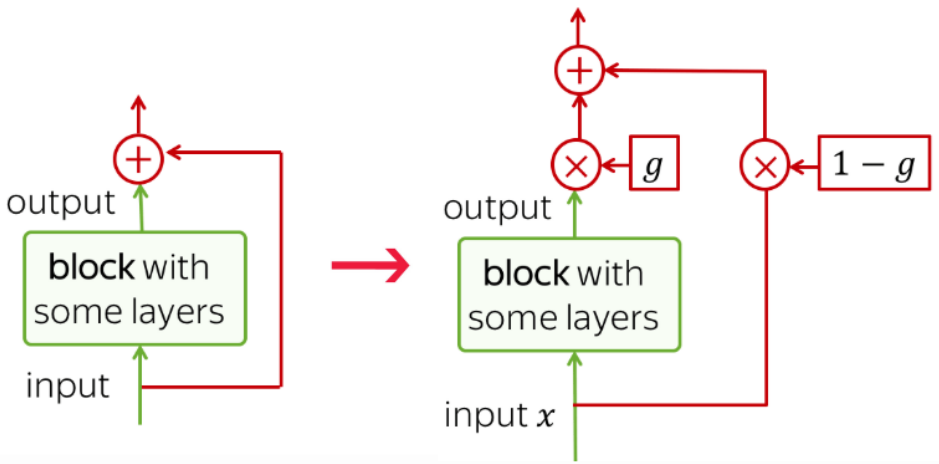
$$w = c_1 c_2 ... c_T$$

- Каждый символ кодируется настраиваемым эмбеддингом $c_t \to \mathbf{e}_t$, получаем матрицу $E \in \mathbb{R}^{D \times T}$.
- Применяем к E одномерные свёртки разного размера.
- Агрегируем по $t = 1, 2, ...T$, используя max-пулинг. Получаем эмбеддинг фикс. длины $\mathbf{s} \in \mathbb{R}^D$
- Применяем 2 highway-слоя (со своими параметрами):

$$\mathbf{x} = \text{Highway}_1 \left(\text{Highway}_2 \left(\mathbf{s} \right) \right)$$

Работает универсально для слов из обучающей выборки и для новых слов!

Highway-слой[2]



Highway-слой - остаточный блок ResNet, где доля сигнала через нелинейность и тождественную связь контролируется $T(x)$:

$$\text{Highway}(\mathbf{x}) = T(\mathbf{x}) \odot H(\mathbf{x}) + \big(1 - T(\mathbf{x})\big) \odot \mathbf{x}$$

$$T(\mathbf{x}) = \sigma\left(W_T\mathbf{x} + \mathbf{b}_T\right)$$
$$H(\mathbf{x}) = g\left(W_H\mathbf{x} + \mathbf{b}_H\right)$$

[2] Elena Voita. NLP Course for You.

Содержание

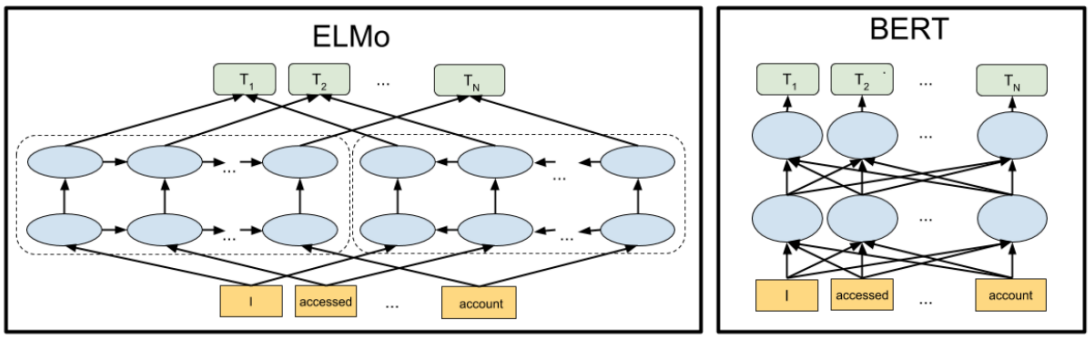
1 Постановка задачи

2 Модель ELMo

3 Модель BERT

4 Извлечение ответа из контекста

BERT[3]



BERT (Bidirectional Encoder Representations) использует кодировщик трансформера.

[3] Devlin J. et al. Bert: Pre-training of deep bidirectional transformers for language understanding //Proceedings of the 2019 conference of the North American chapter of the association for computational linguistics: human language technologies, volume 1 (long and short papers). – 2019. – С. 4171-4186.

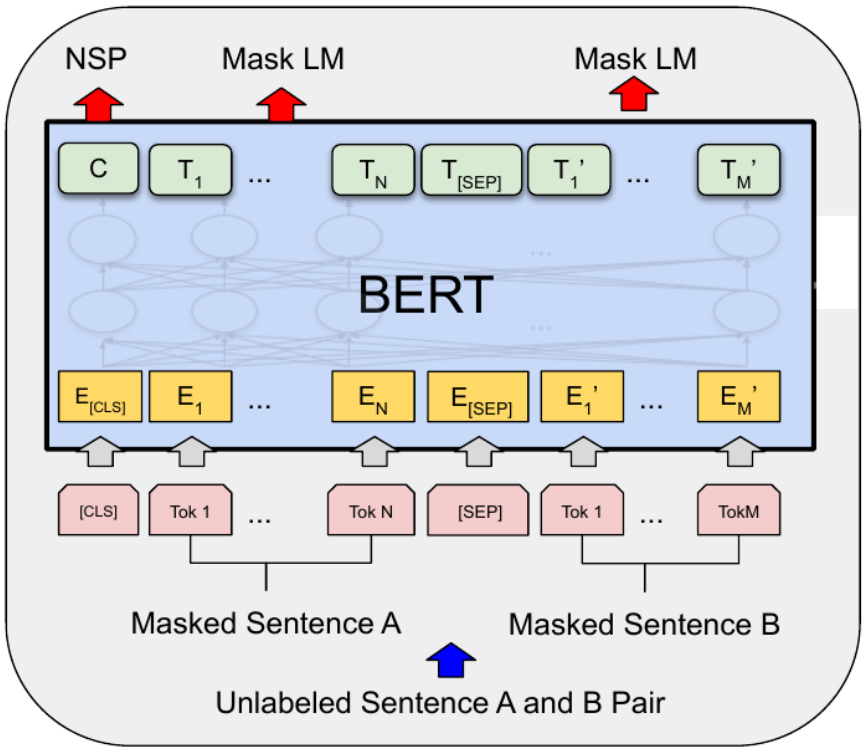
Сравнение BERT и ELMo

- ELMo: контекстные представления через 2 отдельные языковые модели (forward и backward LSTM), которые объединяются постфактум.
  - каждая LSTM не видит весь контекст сразу, а только $\leftarrow$ или $\rightarrow$ часть.
- BERT использует masked language modeling & self-attention.
  - учитывает весь контекст целиком.
- LSTM в ELMo $\rightarrow$ последовательная обработка, медленное обучение&применение.
- BERT: Transformer $\rightarrow$ параллельная обработка всех токенов, эффективно.
- BERT позволяет извлекать эмбеддинги не только для токенов, но и всего предложения целиком.

Задачи, использующие эмбеддинги предложений

- **Обнаружение перефразирований** (Paraphrase Identification)
  - «Он пошёл в магазин», «Он отправился за покупками» → перефразирование
- **Определение логических связей** (Natural Language Inference, NLI)
  - A: «Все кошки животные» B: «Некоторые кошки не млекопитающие» → Противоречие
- **Суммаризация текстов** (text summarization)
  - Документ о климате → выделить предложение «Температура растёт быстрее, чем ожидалось»
- **Классификация текстов**
  - по темам, по тональности
- **Вопросно-ответные системы**
  - Вопрос: «Где находится Эйфелева башня?»
  - Контекст: «Эйфелева башня в Париже»
  - Ответ: «в Париже»

BERT: предобучение (pretraining)



- Вход - два предложения длиной до 512 токенов:

[CLS] **Sentence A tokens** [SEP] **Sentence B tokens** [SEP]

- Вначале всегда подаётся [CLS]-токен
- [SEP]-токен завершает ввод 1го и 2го предложений.

Задачи предобучения

- Модель обучалась одновременно решать 2 задачи:
  - **masked langauge modeling** (MLM)
  - **next sentence prediction** (NSP)

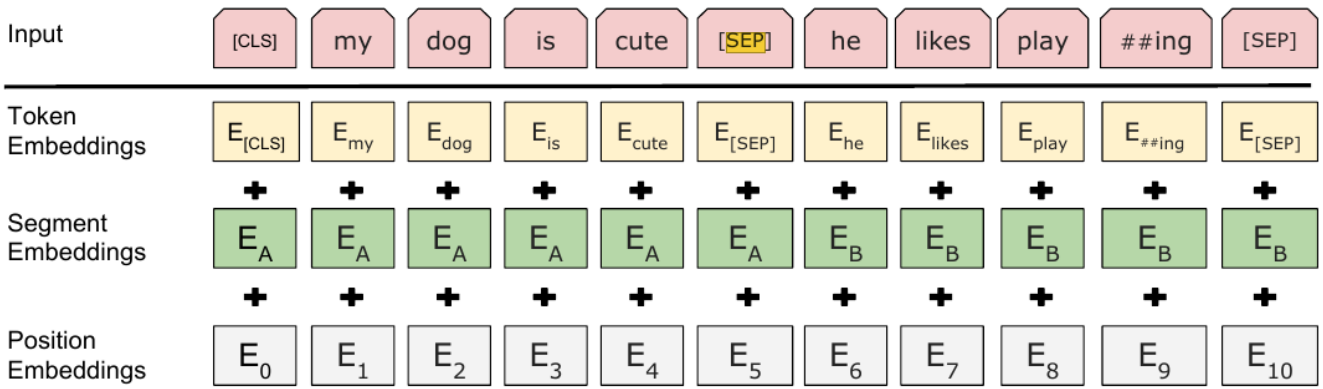
$$\mathcal{L}_{\text{pre-train}} = \mathcal{L}_{\text{MLM}} + \mathcal{L}_{\text{NSP}}$$

- MLM: маскируются случайные токены, и их нужно предсказать по контексту.
  - вер-ти токенов=$SoftMax(FC(\mathbf{e}_i))$
    - $\mathbf{e}_i$-выходной эмбеддинг токена i.
- NSP: бинарная классификация, является ли предложение B продолжением A?
  - вер-ти продолжения/случайного=$SoftMax\left(FC\left(\mathbf{e}_{[CLS]}\right)\right)$.

Генерация данных предобучения

- Входные данные: текст википедии и книг.
- **MLM:**
  - Выбиралось 15% случайных токенов для восстановления.
  - Для каждого из выбранных токенов:
    - 80%: заменялся на [MASK]
    - 10%: оставлялся прежним
    - 10%: заменялся случайным токеном
  - *Важно маскировать не всё, т.к. при применении [MASK]-токенов не будет!*
- **NSP:**
  - Предложение A бралось случайно, а предложение B:
    - 50%: бралось следующим сразу за A
    - 50%: бралось случайным.

Вход модели



$$E_i^{\text{input}} = E_i^{\text{token}} + E_i^{\text{segment}} + E_i^{\text{position}}$$

- Токены кодировались с помощью WordPiece-токенизатора[4]/
  - Имеет встроенную обработку новых слов!
- К каждому эмбеддингу прибавлялись
  - позиционный эмбеддинг (обучаемый)
  - эмбеддинг предложения (1ое или 2ое, обучаемые)

[4] Wu Y. Google's neural machine translation system: Bridging the gap between human and machine translation //arXiv preprint arXiv:1609.08144. – 2016.

Архитектура

- Использовался только кодировщик трансформера.
- $\textbf{BERT}_{\textbf{BASE}}$:
  - 12 слоёв, 768-мерные эмбеддинги, 12 голов внимания. $\sim$110 миллионов параметров.
- $\textbf{BERT}_{\textbf{LARGE}}$:
  - 24 слоя, 1024-мерные эмбеддинги, 16 голов внимания. $\sim$340 миллионов параметров.

GELU-активация

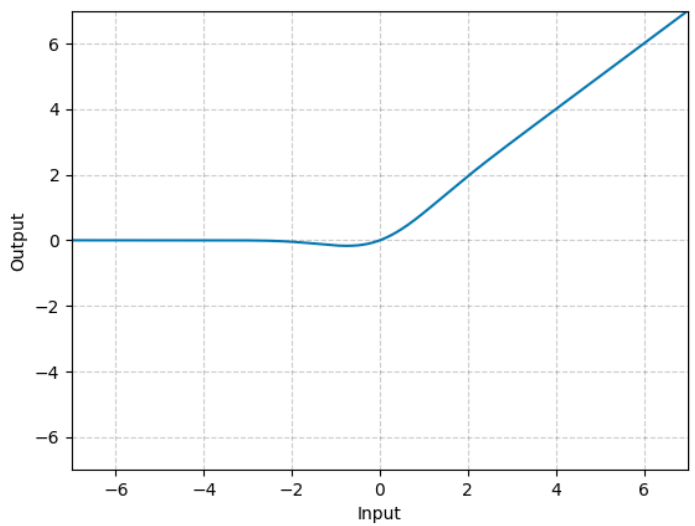
- В FeedForward-слое использовалась активация GELU:

$$\text{GELU}(x) = x \cdot \Phi(x)$$

$\Phi(x)$ - ф-ция распределения (CDF) $\mathcal{N}(0,1)$

- Практическая аппроксимация:

$$\text{GELU}(x) \approx 0.5\, x \left(1 + \tanh\left[\sqrt{2/\pi}\,(x + 0.044715\, x^3)\right]\right)$$



Применение BERT

- Обучив BERT, мы можем добавить собственнный линейный слой на
  - **эмбеддинги слов**
    - для решения задач на уровне слов
  - **эмбеддинг предложения**
    - для решения задач на уровне предложений
- Далее обучается
  - только новый слой (transfer learning)
  - или вся модель целиком (finetuning)
    - когда обучающих данных больше
- При применении:
  - токены не маскируются
  - если подаётся 1 предложение, то в формате:

[CLS] **Sentence tokens** [SEP]

Органичение

- Вход может иметь длину $N \leq 512$.
  - вызвано вычислительной сложностью self-attention ($O(N^2 \cdot D)$).
- Для более длинных входов
  - текст делится на фрагменты
  - фрагменты обрабатываются по отдельности
  - результаты агрегируются

Содержание

1 Постановка задачи

2 Модель ELMo

3 Модель BERT

4 Извлечение ответа из контекста

Извлечение ответа из контекста - задача

- Рассмотрим **задачу извлечения ответа из контекста** (Extractive QA).
- Пример:
  - вопрос: What is the capital of France?
  - контекст: France is located in Europe, it's capital is Paris, which is the largest city in the country.
  - выход: it's capital is Paris.
- Формируем вход для BERT:
  - [CLS] France is located in Europe, it's capital is Paris, which is the largest city in the country. [SEP] What is the capital of France? [SEP]

Извлечение ответа из контекста - решение

- $\mathbf{e}_i \in \mathbb{R}^D$ - выходной эмбеддинг BERT для i-го токена.
- Добавляются два линейных слоя с весами $\mathbf{w}_s, \mathbf{w}_e \in \mathbb{R}^D$ и смещениями $b_s, b_e \in \mathbb{R}$.

Логиты для позиций начала и конца:

$$\overline{s}_i = \mathbf{w}_s^\top \mathbf{e}_i + b_s, \quad \overline{e}_j = \mathbf{w}_e^\top \mathbf{e}_j + b_e$$

Вероятности начала и конца ответа (длина контекста T):

$$P_{\text{start}}(i) = \frac{\exp(\overline{s}_i)}{\sum_{k=1}^T \exp(\overline{s}_k)}, \quad P_{\text{end}}(j) = \frac{\exp(\overline{e}_j)}{\sum_{k=1}^T \exp(\overline{e}_k)}$$

Извлечение ответа из контекста - решение

Предсказание выделения: Найти пару $(\widehat{i}, \widehat{j})$ такую, что:

$$\begin{aligned}
\left(\widehat{i}, \widehat{j}\right) &= \arg\max_{i\le j\le T} P_{\text{start}}(i) \times P_{\text{end}}(j) \\
&= \arg\max_{i\le j\le T} \ln\left(P_{\text{start}}(i) \times P_{\text{end}}(j)\right) \\
&= \arg\max_{i\le j\le T} \left(\ln P_{\text{start}}(i) + \ln P_{\text{end}}(j)\right) \\
&= \arg\max_{i\le j\le T} \left(\overline{s}_i + \overline{e}_j + \text{const}\right) \\
&= \arg\max_{i\le j\le T} \left(\overline{s}_i + \overline{e}_j\right)
\end{aligned}$$

Обучение: Сэмплируем вопрос и контекст. Пусть i^*, j^* — истинные индексы начала и конца ответа. Тогда

$$\mathcal{L}_{\text{QA}} = -\left(\overline{s}_{i^*} + \overline{e}_{j^*}\right) \to \min_{\mathbf{w}_s, \mathbf{w}_e, b_s, b_e}$$

Заключение

- В отличие от статических (Word2Vec, GloVe), контекстные эмбеддинги решают проблему **полисемии** слов.
- BERT позволяют их извлекать лучше, чем RNN:
  - ELMo просто объединяет $\leftarrow$ и $\rightarrow$ контекст
  - а BERT учитывает одновременно
  - attention учитывает долгосрочные связи без забывания.
- BERT позволяет решать задачи на уровне всего предложения, используя эмбеддинг [CLS].
- Примеры задач, решаемых с помощью BERT:
  - классификация текстов, поиск ответа на вопрос, установление связей между текстами.
  - разбор на части речи, определение роли слов, распознавание именованных сущностей
  - подготовка эмбеддингов для вопросно-ответных систем и машинного перевода.