GPT-модели генерации текста

Виктор Китов
victorkitov.github.io



Содержание

1 Модель GPT-1

2 Модель GPT-2

3 Следующие версии

Проблема и цель исследования

- **Проблемы:**
  - NLP-задачи страдают от нехватки размеченных данных.
  - Нужен перенос знаний из большой коллекции неразмеченных текстов.
  - Существующие методы переносят знания только на уровне отдельных слов.
- **Цель:** Создать универсальное представление, требующее минимальной адаптации под разные задачи.
- Для этого была предложена модель GPT-1[1].

[1] Radford A., Narasimhan K., Salimans T., Sutskever I. Improving Language Understanding by Generative Pre-Training. //OpenAI Technical Report. – 2018.

Двухэтапная процедура обучения

- **Этап 1: Обучение базовой языковой модели (unsupervised pre-training)**
  - Обучение на большом неразмеченном корпусе текстов $\mathcal{U} = \{x_1, \ldots, x_n\}$
  - Обучение - предсказание следующего слова:

$$L_1(\mathcal{U}) = \sum_i \log P_\theta(x_i | x_{i-k}, \ldots, x_{i-1}) \to \max_\theta$$

  - Использовался BooksCorpus (7000 книг)
    - на нём была достигнута перплексия 18.4.
- **Этап 2: Дообучение (Fine-tuning)**
  - Дообучение всех параметров модели (fine-tuning) на размеченном датасете $\mathcal{C}$ для конкретной задачи.
  - Для каждой задачи добавлялся только свой линейный слой и спец. токены.
  - Остальная архитектура при этом оставалась прежней!

Архитектура модели[2]

- **Основа:** только декодер трансформера.
- **Конфигурация:**
  - $L = 12$ слоев декодера
  - 768-мерные скрытые состояния, 12 голов внимания
  - позиционные эмбеддинги обучались
  - #параметров=117 млн.
- **Функция активации: GELU** (Gaussian Error Linear Unit).
- **Токенизатор:** Byte-pair encoding (BPE) с 40,000 операциями слияния.
  - инициализация символами языка
- **Dropout** (0.1) для слоев внимания, эмбеддингов и остаточных связей.

[2] Radford A. et al. Improving Language Understanding by Generative Pre-Training. 2018.

Дообучение (supervised fine-tuning)

- Размеченный корпус $\mathcal{C} = \{(x, y)\}_{(x,y)}$.
- Для каждого объекта - предсказание метки y для последовательности токенов $x_1, \ldots, x_m$
- Адаптация: эмбеддинг последнего токена последнего блока трансформера $\mathbf{h}_m^L$ подается в линейный слой W_y:

$$P(y|x^1, \ldots, x^m) = \text{softmax}(W_y \mathbf{h}_m^L)$$

$$L_2 = \sum_{(x,y)} P_\theta \left(y|x_1 x_2 ... x_m\right) \to \max_\theta$$

- Но лучше заработало и использовалось с добавлением критерия языкового моделирования:

$$L_3(\mathcal{C}) = L_2(\mathcal{C}) + \lambda L_1(\mathcal{C}) \to \max_\theta$$

Рассматриваемые задачи: NLI и QA

- **Логический вывод (Natural Language Inference, NLI)**
  - Определение связи: следование, противоречие или нейтрально.
  - *Пример:* «Мальчик играет в мяч», «Мальчик спит» $\rightarrow$ Contradiction.
- **Ответ на вопросы (Question Answering, QA)**
  - Выбор ответа из контекста.
  - *Пример:* Контекст про падение пирога. Вопрос: «Что чувствует герой?». Ответ: Расстроен.

Рассматриваемые задачи: Similarity и Classification

- **Семантическая схожесть (Semantic Similarity)**
  - Эквивалентны ли два предложения?
  - *Пример:* «Он купил новый автомобиль», «Он приобрёл новую машину» $\rightarrow$ Similar.
- **Классификация (Classification)**
  - Грамматическая приемлемость.
  - *Пример:* «Я идти дом завтра» $\rightarrow$ Unacceptable.
  - Анализ тональности (Sentiment).
  - *Пример:* «Этот фильм потрясающий!» $\rightarrow$ Positive.

Трансформация входных данных

Для разных задач адаптировался только промпт[3] с разделителем \$ и токенами <Start>, <Extract>:

- **Логический вывод** (Natural Language Inference):

  $$[<\text{Start}> \text{ Premise } \$ \text{ Hypothesis } <\text{Extract}>]$$

- **Сходство** (Semantic Similarity): Порядок не важен, поэтому подаются оба варианта (A,B) и (B,A), результаты складываются:

  $$[<\text{Start}> \text{ A } \$ \text{ B } <\text{Extract}>] + [\text{Start}> \text{ B } \$ \text{ A } <\text{Extract}>]$$

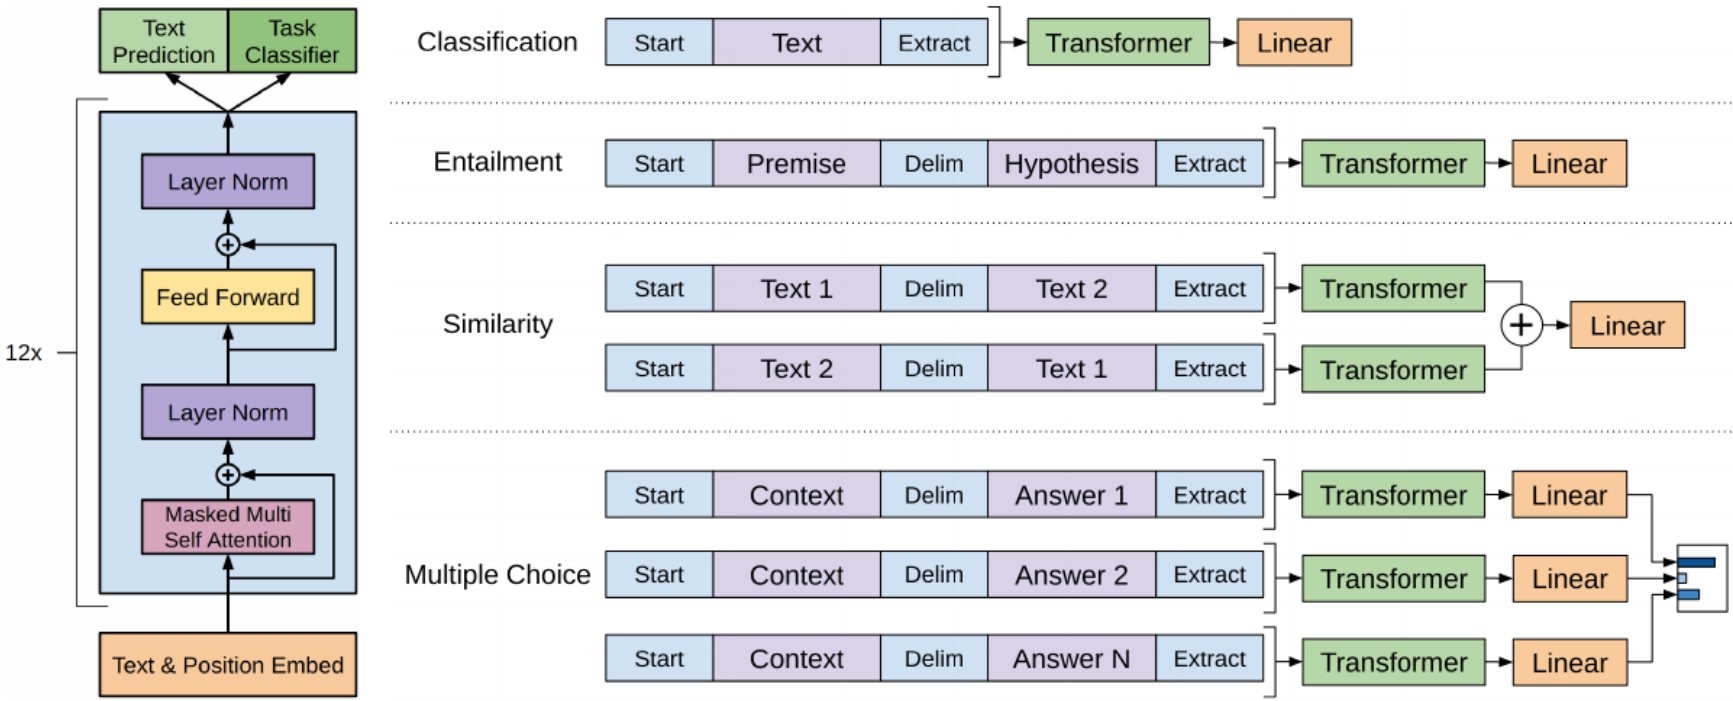
- **Ответ на вопросы** (Question answering): Каждый вариант ответа конкатенируется с контекстом и вопросом:

  $$[<\text{Start}> \text{ Context Question; } \$ \text{ Answer i } <\text{Extract}>]$$

  - выбирается ответ с максимальной вероятностью.

[3] Архитектура базовой модели трансформера везде оставалась неизменной!

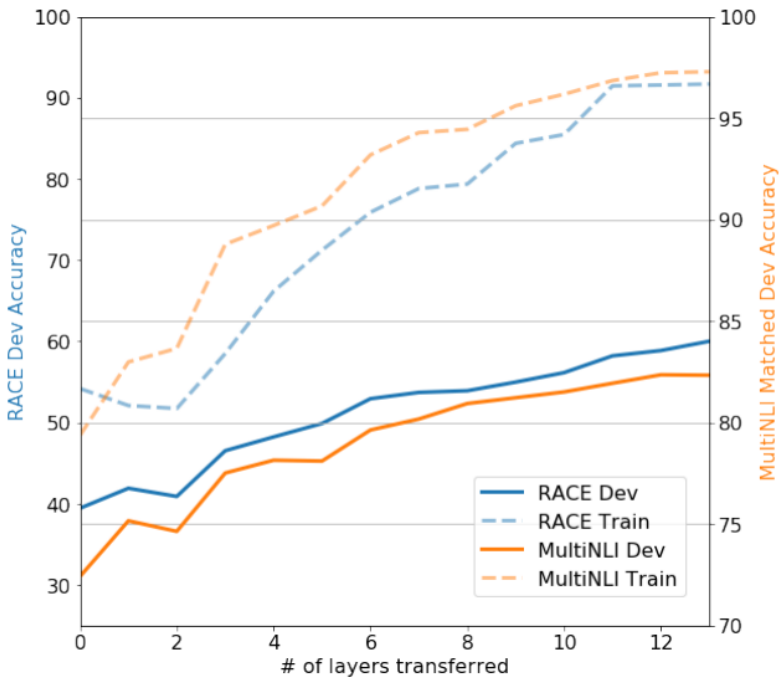
Схема[4]

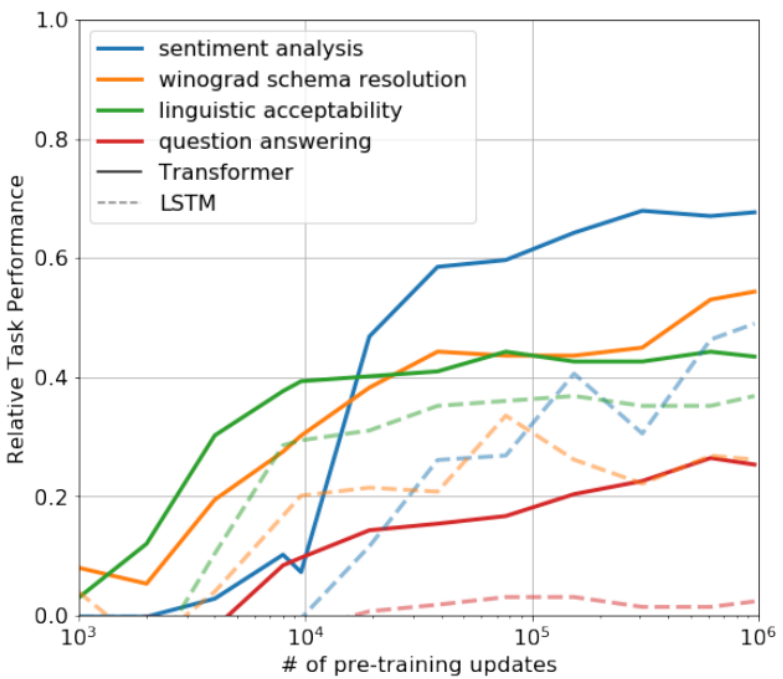


[4] Radford A., Narasimhan K., Salimans T., Sutskever I. Improving Language Understanding by Generative Pre-Training. //OpenAI Technical Report. – 2018.

Зависимость от #слоёв и #итераций обучения[5]

Зависимость качества от #слоёв трансформера (слева) и #итераций обучения при решении в zero-shot режиме без дообучения (справа).





[5] Radford A., Narasimhan K., Salimans T., Sutskever I. Improving Language Understanding by Generative Pre-Training. //OpenAI Technical Report. – 2018.

Выводы

- GPT-1 доказала эффективность трансформера как универсального экстрактора признаков.
- Получены лучшие результаты по разным текстовым задачам.
- Модель начинала «понимать» задачи даже без дообучения.
- Успех GPT-1 заложил основу для масштабирования и развития больших языковых моделей.

Содержание

1 Модель GPT-1

2 Модель GPT-2

3 Следующие версии

От узких экспертов к универсалам

- **Проблема:** Требуется собирать обучающий датасет под каждую задачу.
- **Гипотеза:** Модель может обучаться сразу разным задачам, если
  - её обучать без учителя
  - на достаточно большом и разнообразном корпусе
  - выразительная способность модели велика (глубокий трансформер)
- **Обучение:** Максимизация правдоподобия следующего токена:

$$L(\mathcal{U}) = \sum_i \log P_\theta(x_i|x_{i-k},\dots,x_{i-1}) \to \max_\theta$$

- **Zero-shot применение:** Изменяем только промпт
  - без изменения параметров или архитектуры.

Обучающие данные: WebText

- **Цель:** Создавать
  - максимально большой и разнообразный датасет
  - с качественным контентом (проверенным людьми)
- **Метод:** Сбор всех исходящих ссылок из Reddit, получивших ≥ 3 апвоута.
- **Результат:**
  - Более **8 миллионов** документов.
  - **40 ГБ** чистого текста.
  - Высокое качество и разнообразие доменов.

Архитектурные изменения: Нормализация

Базовая модель - декодировщик трансформера. Отличия от GPT-1:

- **Pre-normalization:** Layer Normalization (LN) перемещена на вход каждого подблока.
  - GPT-1 (Post-norm): $x_{n+1} = \text{LN}(x_n + \text{SubLayer}(x_n))$
  - GPT-2 (Pre-norm):

$$x_{n+1} = x_n + \text{SubLayer}(\text{LN}(x_n))$$

- **Final LN:** Добавлен финальный слой нормализации после последнего блока трансформера:

$$y = \text{LN}_{\text{final}}(h_L)$$

Архитектурные изменения: Инициализация

- **Масштабирование весов:** Чтобы учесть накопление сигнала с $\uparrow N$ (числа residual-блоков декодера) веса всех слоёв перед суммой в residual-блоках при инициализации уменьшаются:

$$W_{\text{residual}} \approx W_{\text{init}} \times \frac{1}{\sqrt{N}}$$

- **Контекст:** 512 $\rightarrow$ **1024** токенов.
- **Размер батча:** 64 $\rightarrow$ **512**.
- **Число блоков:** 12 $\rightarrow$ **48**.
- В результате GPT-2 содержит **1.5 млрд параметров**.
  - но обучались и более компактные альтернативы с 12, 24, 36 блоками.

Byte-level BPE Токенизация

- **Проблема Unicode:** Использование всех символов Unicode создало бы базовый словарь в $> 130,000$ токенов.
- **Решение GPT-2:** BPE на уровне байтов.
  - Базовый словарь — всего **256**.
  - Итоговый словарь — **50,257** токенов.
- **Результат:** Модель может представить любой текст, не встречая токенов неизвестных слов.

Задачи в режиме Zero-shot

Модель не дообучается под задачи, изм-ся только промпт!

- **Суммаризация:** Добавление в конце $\mathrm{TL;DR:}$
- **Перевод:** Контекст из пар:
  $\mathrm{sentence\ in\ english} = \mathrm{sentence\ in\ french}$
  $\mathrm{sentence\ in\ english} =$ [модель генерирует ответ].
- **Ответы на вопросы (QA):**
  - На датасете CoQA $F_1 = 0.55$ без дообучения!
  - Использовался паттерн
    - Контекст
    - Q: [Вопрос 1] A: [Правильный Ответ 1].
    - Q: [Вопрос 2] A: [Правильный Ответ 2].
    - Q: [Целевой вопрос1] A:

GPT-2 решал их с приемлемой точностью (не SOTA)

- SOTA - в задачах генерации продолжения текста.

Пример сгенерированной "новости"

Context (human-written): In a shocking finding, scientist discovered a herd of unicorns living in a remote, previously unexplored valley, in the Andes Mountains. Even more surprising to the researchers was the fact that the unicorns spoke perfect English.

GPT-2: The scientist named the population, after their distinctive horn, Ovid's Unicorn. These four-horned, silver-white unicorns were previously unknown to science.

Now, after almost two centuries, the mystery of what sparked this odd phenomenon is finally solved.

Dr. Jorge Pérez, an evolutionary biologist from the University of La Paz, and several companions, were exploring the Andes Mountains when they found a small valley, with no other animals or humans. Pérez noticed that the valley had what appeared to be a natural fountain, surrounded by two peaks of rock and silver snow.

Pérez and his friends were astonished to see the unicorn herd. These creatures could be seen from the air without having to move too much to see them – they were so close they could touch their horns.

Dr. Pérez believes that the unicorns may have originated in Argentina, where the animals were believed to be descendants of a lost race of people who lived there before the arrival of humans in those parts of South America.

While their origins are still unclear, some believe that perhaps the creatures were created when a human and a unicorn met each other in a time before human civilization. According to Pérez, "In South America, such incidents seem to be quite common."

However, Pérez also pointed out that it is likely that the only way of knowing for sure if unicorns are indeed the descendants of a lost alien race is through DNA. "But they seem to be able to communicate in English quite well, which I believe is a sign of evolution, or at least a change in social organization," said the scientist.

Выводы

- Языковое моделирование позволяет решать многие задачи напрямую без дообучения под каждую.
- Промпт-инжиниринг таргетирует модель решать нужную задачу.
  - примеры решения в промпте $\uparrow$ качество
- Важна большая и качественная обучающая выборка.
- Более глубокие модели лучше.
  - более глубокая версия показывала лучшее качество
  - но максимальная GPT-2 всё ещё недообучалась под WebText

Содержание

1 Модель GPT-1

2 Модель GPT-2

3 Следующие версии

GPT-3: In-context Learning[6]

- **Параметры:** 175 млрд.
- **Концепция:** Few-shot Learners, модель понимает задачу по нескольким примерам в промпте без изменения весов.
- **Возможности:**
  - Генерация кода, написание эссе, решение логических тестов.
  - Впечатляющая связность длинных текстов.
- **Слабость:** Трудности со здравым смыслом (common sense) и склонность к галлюцинациям.

[6] Brown T. et al. Language models are few-shot learners //Advances in neural information processing systems. – 2020. – Т. 33. – С. 1877-1901. //arXiv preprint arXiv:2005.14165. – 2020.

GPT-3.5: InstructGPT & RLHF[7]

- **Выравнивание (Alignment):** Решение проблемы несоответствия целей модели и пользователя.
- **Метод: RLHF** (Reinforcement Learning from Human Feedback).
  1. Люди оценивают ответы модели.
  2. Модель награды (Reward Model) учится предсказывать оценки людей.
  3. Модель оптимизируется через PPO.
- **Итог:** Появление **ChatGPT**. Модель следует инструкциям и ведет диалог.

[7] Ouyang L. et al. Training language models to follow instructions with human feedback //Advances in neural information processing systems. – 2022. – Т. 35. – С. 27730-27744.

GPT-4: Multi-modality & Reasoning[8]

- **Мультимодальность:** Анализ изображений и текста (Vision).
- **Надежность:** Значительное снижение частоты галлюцинаций и токсичности.
- **Ключевые показатели:**
  - Успешное прохождение Uniform Bar Exam и тестов GRE/SAT.
  - Контекстное окно до 128 000 токенов (в Turbo версиях).
- **Развитие:** GPT-4o (Omni) — работа с голосом и видео в реальном времени.

[8] Achiam J. et al. Gpt-4 technical report //arXiv preprint arXiv:2303.08774. – 2023.